



POLYTECH DIJON

RAPPORT DE BIG DATA

Analyse d'un dataset de main de Poker

(Via Kmeans et PCA)

Auteur :
Yohann TURPIN

Date :
7 janvier 2026

Année Universitaire 2025 – 2026

Table des matières

1	Introduction et Règles du Texas Hold'em	3
2	Description du Jeu de Données	4
2.1	Origine et Volume	4
2.2	Structure initiale des données	4
3	Nettoyage et Feature Engineering	5
3.1	Création de nouvelles variables	5
4	Présentation des Résultats et Clustering	6
4.1	Méthode du Coude et score de Silhouette	6
4.2	Analyse des Métriques et Centroïdes	6
4.3	Interprétation Stratégique des Clusters	7
5	Parallèle avec les Mains Réelles	8
5.1	Affinements de la Logique Métier	8
5.2	Tableau Décisionnel Stratégique	8
5.3	Visualisation : La Hand Range Tab Finale	8
6	Conclusion	9

Table des figures

1	Graphique permettant le choix de K	6
2	Matrice 13×13 des mains de départ classées par Cluster (Version Finale) .	9

1 Introduction et Règles du Texas Hold'em

Le Texas Hold'em est la variante de poker la plus populaire au monde. Chaque joueur reçoit deux cartes privées, appelées *hole cards*. Le but est de former la meilleure combinaison de cinq cartes en utilisant ses deux cartes et cinq cartes communes distribuées progressivement par le croupier au centre de la table.

Le déroulement d'une main s'organise autour de trois étapes de distribution des cartes communes, séparées par des intervalles d'enchères :

- **Le Flop** : Le croupier tire et retourne les trois premières cartes communes.
- **Le Turn** : Le croupier ajoute une quatrième carte commune.
- **La River** : Le croupier dévoile la cinquième et dernière carte commune.

À chaque étape de la distribution, ainsi qu'au début du coup (*Pré-flop*), les joueurs doivent prendre des décisions stratégiques lors des tours de mise. Trois actions principales s'offrent à eux :

- **Relancer (Raise)** : Augmenter le montant de l'enchère actuelle pour valoriser sa main ou bluffer.
- **Suivre (Call)** : S'aligner sur la mise la plus haute effectuée précédemment pour rester dans le coup.
- **Se retirer (Fold)** : Rendre ses cartes au croupier et quitter la main en cours pour limiter ses pertes.

Cette structure implique que la force d'une main évolue dynamiquement entre le début du coup et la *River*. Cette progression mathématique permet de définir deux concepts clés analysés dans ce projet : la "**force immédiate**" (valeur actuelle de la main) et le "**potentiel d'évolution**" (probabilité d'amélioration via les tirages).

2 Description du Jeu de Données

Le jeu de données utilisé pour ce projet provient de la plateforme **Kaggle**¹.

2.1 Origine et Volume

Le dataset se compose d'**un million d'enregistrements**, ce qui permet d'obtenir une représentativité statistique élevée pour chaque combinaison possible. Même s'il faudra utiliser certaines optimisations afin de faire parler les données, on aura la surprise de voir apparaître des informations utiles et concrètes.

2.2 Structure initiale des données

Contrairement à une simple liste de cartes, la structure initiale du fichier est séquentielle et retrace l'évolution complète d'un coup :

- **Main du joueur** : La première colonne définit les deux cartes privées reçues au départ.
- **Séquences du croupier** : Les colonnes suivantes détaillent les cartes révélées successivement lors du *Flop*, du *Turn* et de la *River*.
- **Résultats intermédiaires** : À chaque mise à jour de la table (après chaque nouvelle carte posée par le croupier), le dataset fournit un résultat indiquant la **meilleure combinaison de cartes possible** à cet instant précis.

Cependant, malgré cette richesse, ces données brutes sous forme de chaînes de caractères ou de rangs isolés sont peu exploitables par un algorithme de clustering. Un travail de *feature engineering* est donc indispensable pour obtenir des informations que l'on pourra traiter, et peut être même prédire une possible victoire ou non.

1. Lien vers Kaggle

3 Nettoyage et Feature Engineering

La phase cruciale a consisté à transformer ces données brutes en variables descriptives à forte valeur ajoutée.

3.1 Création de nouvelles variables

Nous avons créé les caractéristiques suivantes pour capturer l'essence tactique d'une main :

- **high_card** : Valeur de la carte la plus haute (force brute).
- **is_pair** : Variable binaire indiquant une paire servie.
- **is_suited** : Indique si les deux cartes sont de la même couleur (potentiel de couleur).
- **is_connector** : Indique si les cartes se suivent (potentiel de suite).
- **force_flop** et **force_river** : Scores de force aux deux étapes clés.
- **evolution_main** : Différence entre la force à la River et au Flop, mesurant le gain de puissance.

4 Présentation des Résultats et Clustering

4.1 Méthode du Coude et score de Silhouette

Afin de déterminer le nombre optimal de groupes pour notre segmentation, nous avons utilisé la méthode du coude et du score de silhouette.




FIGURE 1 – Graphique permettant le choix de K

D'après ces résultats, nous avons le choix d'un nombre k clusters compris entre 5 et 7. J'ai choisi de prendre $k=7$, afin de maximiser le score de silhouette, mais aussi pour avoir le résultat le plus fin possible.

4.2 Analyse des Métriques et Centroïdes

Le tableau ci-dessous présente les caractéristiques moyennes (centroïdes) pour chaque cluster. Ces valeurs numériques permettent de comprendre "l'identité" de chaque groupe.

TABLE 1 – Moyennes des features numériques par cluster

Cluster	force_flop	force_river	evolution_main	is_suited	card_gap	high_card	is_pair	is_connector
0	0.531	1.091	0.560	0.000	7.021	12.480	0.000	0.000
1	0.593	1.465	0.871	0.248	1.000	8.474	0.000	1.000
2	1.445	2.096	0.650	0.000	0.000	11.069	0.999	0.000
3	0.593	4.762	4.169	0.321	4.771	10.466	0.000	0.036
4	0.595	1.149	0.553	1.000	5.393	10.705	0.000	0.000
5	0.555	1.116	0.561	0.000	3.347	8.483	0.000	0.000
6	1.447	2.196	0.749	0.000	0.000	4.567	0.999	0.000

Comprendre les valeurs :

- Les scores de **force** (flop/river) et d'**évolution** correspondent aux rangs classiques du poker (0 : Hauteur, 1 : Paire, 2 : Double Paire, 3 : Breton, 4 : Quinte, 5 : Couleur, etc.).
- Une valeur de **evolution_main** proche de 4 (comme dans le Cluster 3) signifie qu'en moyenne, la main s'est améliorée de 4 crans dans la hiérarchie entre le début et la fin du coup (passant par exemple d'une simple "Hauteur" à une "Quinte" ou une "Couleur").
- Les colonnes *is_suited*, *is_pair* et *is_connector* sont des probabilités moyennes (proches de 1 si la caractéristique définit le cluster).

4.3 Interprétation Stratégique des Clusters

À l'aide des résultats obtenus, nous pouvons dresser un portrait robot de chaque cluster pour mieux comprendre la réalité du jeu qu'ils représentent :

Cluster 0 : Les Mains Hautes "Sèches" Ce groupe contient des cartes fortes (moyenne de 12.48, soit des As ou des Rois) mais sans aucune connexion. Avec un écart important entre les cartes (gap de 7.02) et aucune possibilité de suite ou couleur, l'évolution est faible. On mise ici sur la force brute d'une paire haute éventuelle.

Cluster 1 : Les Connecteurs (Tirages Quinte) Ce sont des mains qui se suivent ($is_connector = 1.0$). Elles ont environ 25% de chances d'être assorties. Bien que faibles au départ, elles offrent une réelle possibilité de construire une quinte ou une couleur au cours du jeu.

Cluster 2 : Les Paires Hautes Le cluster des As, Rois et Dames servis. La force au flop est déjà élevée (1.44). S'il y a peu d'évolution spectaculaire, c'est parce que la main est déjà forte : elle sécurise souvent le pot avec une double paire ou un brelan solide.

Cluster 3 : Le Coup de Chance C'est le cluster statistique de "la chance". Il regroupe des mains initialement quelconques qui ont fini par toucher un jeu monstrueux à la River (force river de 4.76). C'est le seul groupe affichant une évolution moyenne de plus de 4 crans.

Cluster 4 : Les Mains Assorties (Suited) Ici, 100% des mains sont de la même couleur. Le gap est élevé, indiquant qu'aucune suite n'est prévue. L'unique objectif de ce groupe est de "chasser" la couleur (*flush*).

Cluster 5 : Les Mains "Poubelles" (Trash) Ce groupe représente le bruit de fond du dataset. Les cartes sont basses (8.48), non connectées et non assorties. Ce sont des mains sans aucun potentiel que le joueur devrait systématiquement coucher.

Cluster 6 : Les Petites Paires Des paires basses (moyenne de 4.56, soit des paires de 4 ou 5). Bien que leur force initiale semble modeste, elles sont précieuses pour sécuriser une petite double paire ou créer la surprise avec un brelan caché (*set*).

5 Parallèle avec les Mains Réelles

Pour valider la pertinence de notre modèle de clustering dans un environnement de jeu réel, nous avons généré une *Hand Range Tab* (matrice 13×13). Cette étape permet de confronter les résultats statistiques purs à la théorie classique du poker.

5.1 Affinements de la Logique Métier

L'application brute du K-Means a nécessité quelques ajustements manuels pour correspondre aux impératifs stratégiques :

- **Affinement métier** : Nous avons manuellement ajusté les paires inférieures à 4 (22 et 33) vers le Cluster 5. Bien que statistiquement isolées comme des paires, leur rentabilité réelle est trop proche des mains nulles car elles perdent presque toujours sans un brelan.
- **Filtre de force** : Le Cluster 4 (mains assorties) a été optimisé pour ne conserver que les combinaisons possédant un "kicker" solide (≥ 9). Les petites cartes assorties (ex : 72s) ont été reléguées en catégorie "Trash" (Cluster 5), car le simple potentiel de couleur ne compense pas leur manque de force brute.

5.2 Tableau Décisionnel Stratégique

Le tableau suivant récapitule les stratégies recommandées par notre modèle en fonction du potentiel de victoire identifié par les clusters :

TABLE 2 – Synthèse des stratégies de jeu par Cluster

Potentiel	Cluster	Action	Raisonnement	Gestion du Pot / Bluff	Max Hand
Très Élevé	2	Miser / Relancer	Paires hautes (AA, KK). Domination totale.	Gros Pots. Pas de bluff, se faire payer par moins bien.	Carré / Full
Élevé	0	Miser / Relancer	Cartes hautes (A, K). Avantage au "kicker".	Pots Moyens. Idéal pour le bluff si le flop est effrayant.	Quinte / Paire Max
Fort / Surnois	6	Suivre	Cherche le brelan (Set Mining). Invisible.	Énormes Pots. Laisser l'autre miser pour tout lui prendre.	Brelan / Full
Modéré	1 & 4	Suivre	Mains à potentiel (Suite/Couleur). Voir le flop.	Pots Moyens. Semi-Bluff pour simuler le tirage complété.	Q. Flush / Couleur
Exceptionnel	3	Tapis (All-in)	Tirage complété. Evolution > 4 .	Pot Maximum. Simuler un bluff pour être payé.	Q. Flush Royale
Nul	5	Se Coucher	Aucune force, aucun potentiel.	Pots Nuls. Abandon immédiat pour préserver son tapis.	Paire basse

5.3 Visualisation : La Hand Range Tab Finale

La figure ci-dessous représente la classification finale de toutes les combinaisons de départ possibles au Texas Hold'em. Elle constitue l'outil ultime d'aide à la décision découlant de notre clustering.




FIGURE 2 – Matrice 13×13 des mains de départ classées par Cluster (Version Finale)

Analyse de la matrice : On observe une répartition logique : la diagonale jaune et orange isole les paires (Clusters 2 et 6). Le triangle supérieur (suited) est dominé par le Cluster 4 (violet), tandis que les cartes hautes dépareillées (triangle inférieur) sont capturées par le Cluster 0 (bleu). On note que le Cluster 3 (en vert sur certains tirages spécifiques) n'est pas représenté ici car il dépend de l'évolution post-flop, impossible à prévoir lors de la réception des cartes de départ.

6 Conclusion

Ce projet démontre avec succès que les algorithmes d'apprentissage non-supervisé, et plus particulièrement le **K-Means**, peuvent segmenter efficacement la complexité stratégique du Texas Hold'em. L'analyse ne s'est pas contentée de regrouper les mains par leur simple valeur faciale, mais par leur **comportement probabiliste** et leur **espérance de gain** au fil des tours.

Grâce à un travail poussé de *feature engineering*, notamment avec la création de la variable *evolution_main*, nous avons pu distinguer la **force immédiate** (Cluster 2) du **potentiel spéculatif** (Clusters 1, 4 et 6). Le choix d'un modèle à $k = 7$ clusters s'est avéré optimal pour isoler des phénomènes critiques tels que les petites paires ou les tirages miraculeux du Cluster 3, souvent invisibles lors d'une analyse linéaire classique.

De plus, même si on a déjà réussi à en tirer des stratégies via les différents clusters, il y a aussi eu la possibilité d'un parallèle avec les différentes mains possibles. En effet, la matrice obtenue à la fin, ressemble assez bien aux matrices créées par les joueurs de Poker permettant de savoir quelles sont les mains les plus fortes en fonction de leurs positions sur la table.

Code source et ressources du projet :

Retrouvez l'intégralité du code Python, du nettoyage des données et des visualisations
sur mon dépôt GitHub :

[Lien du GitHub](#)